

第二部分：Batch Normalization 实验报告

神经网络与深度学习 Project 2

2026 年 6 月 8 日

摘要

本报告只对应 Project 2 的第二部分 Batch Normalization。实验以 CIFAR-10 图像分类为任务，比较标准 VGG-A 与在每个卷积层后加入 Batch Normalization 的 VGG-A-BN。我们首先完成 BN 层的结构实现与基础训练对比，然后按照作业要求从损失包络、学习率敏感性和梯度变化三个角度分析 BN 对优化过程的影响。基础实验表明，在学习率 10^{-3} 下，VGG-A-BN 的最佳验证准确率达到 82.18%，高于无 BN 模型的 77.97%；在学习率 2×10^{-3} 下，无 BN 模型退化到接近随机猜测的 10.00%，而 BN 模型仍达到 81.36%。跨学习率的 loss landscape 包络宽度从无 BN 的平均 1.900 降至 BN 的 0.375，约减少 80.3%。这些结果说明，BN 的主要贡献不只是提升最终精度，更重要的是改善优化稳定性、扩大可用学习率范围，并使训练过程对超参数变化更鲁棒。

目录

1	实验目标与代码结构	3
2	Batch Normalization 方法	3
2.1	BN 的计算形式	3
2.2	VGG-A 与 VGG-A-BN 实现	3
3	基础实验设置	4
3.1	数据集与预处理	4
3.2	训练配置	4
4	VGG-A 与 VGG-A-BN 基础对比	5
4.1	主要分类结果	5
4.2	训练曲线分析	5
5	BN 对 Loss Landscape 的影响	6
5.1	包络式 loss landscape 度量	6
5.2	包络宽度定量分析	6
6	学习率敏感性扩展实验	7
6.1	实验设计	7
6.2	结果	7

目录	2
7 梯度预测性分析	8
7.1 度量定义	8
7.2 结果与解释	8
8 增强可视化实验	9
8.1 论文风格训练曲线	9
8.2 三维 loss surface 可视化	10
8.3 激活分布可视化	11
9 综合分析	12
9.1 BN 对性能的影响	12
9.2 BN 对优化稳定性的影响	12
9.3 局限性	12
10 结论	13

1 实验目标与代码结构

本部分任务要求比较带 BN 与不带 BN 的 VGG-A，并进一步分析 BN 如何帮助优化。围绕这一目标，本实验完成了三类工作。

第一，基于提供的 `codes/VGG_BatchNorm` 脚手架，在 `Batch_Normalization` 中实现了可独立运行的实验代码。核心文件包括：

- `models.py`: 实现 CIFAR-10 输入尺寸下的 VGG-A 与 VGG-A-BatchNorm;
- `data_utils.py`: 实现 CIFAR-10 数据加载、归一化与子集调试;
- `run_bn_experiments.py`: 实现训练、验证、loss 记录、梯度范数记录和 loss landscape 包络图生成。

第二，在 `Batch_Normalization/Enhanced` 中补充学习率敏感性与梯度预测性实验，用于从优化角度进一步解释 BN 的作用。

第三，在 `Batch_Normalization/Visual` 中构建报告级可视化脚本，基于基础实验结果与已保存 checkpoint 生成训练曲线、三维 loss surface 以及激活分布 ridgeline 图。所有可视化均围绕基础 BN 实验，不使用额外模型结构的扩展结果。

2 Batch Normalization 方法

2.1 BN 的计算形式

本实验关注卷积神经网络中的二维 Batch Normalization。设某一 BN 层输入为四维张量 $I_{b,c,x,y}$ ，其中 b 表示 mini-batch 内样本编号， c 表示通道， x, y 表示空间位置。BN 对同一通道的所有 batch 与空间位置共同统计均值和方差：

$$\mu_c = \frac{1}{|\mathcal{B}|} \sum_{b,x,y} I_{b,c,x,y}, \quad (1)$$

$$\sigma_c^2 = \frac{1}{|\mathcal{B}|} \sum_{b,x,y} (I_{b,c,x,y} - \mu_c)^2. \quad (2)$$

随后进行标准化和可学习仿射变换：

$$O_{b,c,x,y} = \gamma_c \frac{I_{b,c,x,y} - \mu_c}{\sqrt{\sigma_c^2 + \epsilon}} + \beta_c. \quad (3)$$

其中 γ_c, β_c 是可学习参数。训练阶段使用当前 mini-batch 的统计量，同时维护 running mean 和 running variance；测试阶段使用训练过程中累计得到的 running statistics。

2.2 VGG-A 与 VGG-A-BN 实现

基础网络采用适配 CIFAR-10 的 VGG-A。输入图像大小为 $32 \times 32 \times 3$ ，卷积部分的通道配置为

$$64, M, 128, M, 256, 256, M, 512, 512, M, 512, 512, M,$$

其中 M 表示 2×2 max pooling。卷积部分最终输出 $512 \times 1 \times 1$ 特征，再经过三层全连接分类器：

$$512 \rightarrow 512 \rightarrow 512 \rightarrow 10.$$

无 BN 模型采用标准结构

$$\text{Conv2d} \rightarrow \text{ReLU}.$$

带 BN 模型在每个卷积层后加入 BN：

$$\text{Conv2d} \rightarrow \text{BatchNorm2d} \rightarrow \text{ReLU}.$$

由于 BN 层已经包含可学习的平移与缩放参数，带 BN 的卷积层不使用 bias。参数量方面，VGG-A 有 9,750,922 个参数，VGG-A-BN 有 9,753,674 个参数。二者参数量几乎一致，因此性能差异主要来自 BN 对训练动态和优化过程的影响，而不是模型容量显著增加。

3 基础实验设置

3.1 数据集与预处理

所有实验均在 CIFAR-10 上进行。训练集包含 50,000 张图像，测试集包含 10,000 张图像。输入图像先转换为 tensor，再按 CIFAR-10 经验均值和标准差归一化：

$$\mu = (0.4914, 0.4822, 0.4465), \quad \sigma = (0.2470, 0.2435, 0.2616).$$

基础 BN 实验默认不使用随机裁剪、随机翻转等数据增强，因为本部分重点是比较 BN 对优化过程的影响，而不是追求最高分类精度。

3.2 训练配置

基础训练配置见表 1。为保证对比公平，BN 与 no-BN 使用完全相同的优化器、batch size、epoch 数、随机种子和学习率列表。

表 1: 基础 BN 对比实验配置

项目	设置
数据集	CIFAR-10
模型	VGG-A / VGG-A-BatchNorm
Epoch	20
Batch size	128
优化器	Adam
Weight decay	5×10^{-4}
学习率	$10^{-3}, 2 \times 10^{-3}, 5 \times 10^{-4}, 10^{-4}$
随机种子	2020
数据增强	无

每次训练均记录每个 batch 的训练 loss、每个 epoch 的训练准确率与验证准确率，并保存 best.pt 与 last.pt。这些结果用于后续 loss landscape、可视化和报告分析。

4 VGG-A 与 VGG-A-BN 基础对比

4.1 主要分类结果

表 2 总结了四组学习率下 no-BN 与 BN 的训练结果。可以看到, BN 在中等和偏大学习率下优势明显, 尤其是 2×10^{-3} 时, 无 BN 模型训练失败, 验证准确率停留在随机分类水平; 而 BN 模型仍然取得 81.36% 的最佳验证准确率。

表 2: 基础实验中不同学习率下 VGG-A 与 VGG-A-BN 的性能对比

学习率	模型	最佳验证准确率	最佳 epoch	最终验证准确率
10^{-4}	VGG-A	76.84%	13	76.28%
10^{-4}	VGG-A-BN	74.71%	17	74.34%
5×10^{-4}	VGG-A	79.25%	19	78.12%
5×10^{-4}	VGG-A-BN	81.82%	19	78.17%
10^{-3}	VGG-A	77.97%	18	77.79%
10^{-3}	VGG-A-BN	82.18%	12	81.03%
2×10^{-3}	VGG-A	10.00%	1	10.00%
2×10^{-3}	VGG-A-BN	81.36%	19	79.53%

从平均表现看, 四个学习率下 no-BN 的平均最佳验证准确率为 61.02%, BN 为 80.02%。由于 no-BN 在 2×10^{-3} 下完全失效, 这一平均值差距很大。若只观察正常收敛的学习率, BN 在 5×10^{-4} 和 10^{-3} 下也分别带来 2.57 和 4.21 个百分点的最佳准确率提升。

4.2 训练曲线分析

图 1 展示了学习率 10^{-3} 下的训练 loss 和验证准确率变化。BN 模型从第一个 epoch 开始就表现出更快的优化速度: 第 1 个 epoch 后, BN 的验证准确率达到 60.89%, 而 no-BN 为 36.96%; 第 3 个 epoch 后, BN 已达到 74.66%, no-BN 为 60.28%。最终 BN 在第 12 个 epoch 达到最高验证准确率 82.18%, 比 no-BN 的最高点更早出现。




图 1: 学习率 10^{-3} 下 VGG-A 与 VGG-A-BN 的训练 loss 与验证准确率对比。BN 模型收敛更快, 并在较早 epoch 达到更高验证准确率。

这一结果说明 BN 在本实验中不仅提高了最终精度，而且改变了训练早期的优化动态，使网络更快进入有效分类状态。

5 BN 对 Loss Landscape 的影响

5.1 包络式 loss landscape 度量

作业说明建议选择多组学习率，并在同一训练 step 上统计不同学习率下 loss 的最大值与最小值，形成

$$\max_curve(t) = \max_i L_i(t), \quad \min_curve(t) = \min_i L_i(t),$$

其中 i 表示不同学习率的训练 run。两条曲线之间的区域可理解为在不同步长下训练 loss 的波动包络。包络越宽，说明训练过程对学习率变化越敏感；包络越窄，说明优化过程更稳定。

图 2 展示了 no-BN 与 BN 的 loss 包络对比。无 BN 模型的包络长期覆盖到交叉熵约 2.3 附近，这是因为 2×10^{-3} 学习率下模型几乎停留在随机猜测状态。相比之下，BN 模型的 loss 区域更低且更窄，说明不同学习率下的训练行为更加一致。



图 2: 跨学习率 loss landscape 包络。BN 显著缩小不同学习率训练曲线之间的 loss 波动范围。

5.2 包络宽度定量分析

表 3 给出了包络宽度的统计量。BN 的平均包络宽度为 0.375，无 BN 为 1.900；BN 的平均宽度约为 no-BN 的 19.7%，即缩小约 80.3%。中位数宽度也从 2.077 降至 0.355。

表 3: Loss landscape 包络宽度统计

模型	平均宽度	中位数宽度	90 分位宽度	最大宽度
VGG-A	1.900	2.077	2.262	3.603
VGG-A-BN	0.375	0.355	0.564	3.948

最大宽度上 BN 略高，主要来自训练初期个别 batch 的尖峰；但从平均、中位数和 90 分位数看，BN 的整体包络显著更窄。更重要的是，BN 包络的平均上界为 0.591，而 no-BN 的平均上界为 2.303，这直接反映了 no-BN 在某些学习率下无法有效优化。

6 学习率敏感性扩展实验

6.1 实验设计

为了系统验证 BN 是否扩大可用学习率范围，我们进一步在 **Enhanced** 中运行学习率 sweep。学习率列表扩展为

$$5 \times 10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 2 \times 10^{-3}, 3 \times 10^{-3}, 5 \times 10^{-3}.$$

其他设置保持不变：CIFAR-10、20 epoch、batch size 128、Adam、weight decay 5×10^{-4} 、无数数据增强。

6.2 结果

表 4 与图 3 显示了不同学习率下的最佳验证准确率。BN 的表现随学习率变化更平滑：其最佳准确率在 70.58% 至 82.18% 之间，标准差为 0.041；no-BN 的范围为 10.00% 至 79.25%，标准差为 0.296。

表 4: 学习率敏感性实验结果

学习率	VGG-A 最佳准确率	VGG-A-BN 最佳准确率	BN 提升
5×10^{-5}	75.09%	70.58%	-4.51 pp
10^{-4}	76.84%	74.71%	-2.13 pp
5×10^{-4}	79.25%	81.82%	+2.57 pp
10^{-3}	77.97%	82.18%	+4.21 pp
2×10^{-3}	10.00%	81.36%	+71.36 pp
3×10^{-3}	10.00%	79.46%	+69.46 pp
5×10^{-3}	65.49%	75.00%	+9.51 pp




图 3: 学习率敏感性曲线。BN 在 5×10^{-4} 至 5×10^{-3} 区间保持较高准确率，而无 BN 在 2×10^{-3} 和 3×10^{-3} 下明显失效。

这一结果支持如下判断：BN 的优势在小学习率下并不必然体现，因为此时优化步长较保守，标准 VGG-A 也能稳定下降；但当学习率增大时，BN 显著提高了训练鲁棒性，使模型能够承受更大的参数更新。

7 梯度预测性分析

7.1 度量定义

为了进一步接近作业中提到的“gradient predictiveness”，我们记录相邻 step 的梯度变化。设第 t 步的参数为 w_t ，梯度为 $g_t = \nabla L(w_t)$ ，定义：

$$\Delta_g(t) = \|g_t - g_{t-1}\|_2, \quad (4)$$

$$r_g(t) = \frac{\|g_t - g_{t-1}\|_2}{\|g_{t-1}\|_2 + \epsilon}, \quad (5)$$

$$c_g(t) = \frac{g_t^\top g_{t-1}}{\|g_t\|_2 \|g_{t-1}\|_2 + \epsilon}, \quad (6)$$

以及距离归一化的最大梯度差异：

$$D_g(t) = \frac{\|g_t - g_{t-1}\|_2}{\|w_t - w_{t-1}\|_2 + \epsilon}. \quad (7)$$

其中 r_g 越小、 c_g 越大，通常表示相邻 step 的梯度方向更一致，局部线性近似更有预测性。

7.2 结果与解释

表 5 展示了 10^{-3} 和 2×10^{-3} 两个学习率下的梯度统计。需要注意的是，梯度指标本身容易受是否成功训练影响。例如在 2×10^{-3} 下，无 BN 模型已经退化到随机猜测附近，其梯度范数和

梯度变化都很小，这并不代表优化景观良好，而是模型没有进入有效学习状态。因此该表需要结合验证准确率一起解释。

表 5: 梯度预测性统计

学习率	模型	最佳准确率	平均相对梯度变化	平均梯度余弦	最大 D_g
10^{-3}	VGG-A	77.97%	1.338	0.170	79.59
10^{-3}	VGG-A-BN	82.18%	1.368	0.144	49.46
2×10^{-3}	VGG-A	10.00%	1.490	0.003	21.62
2×10^{-3}	VGG-A-BN	81.36%	1.353	0.154	29.59

图 4 给出了学习率 10^{-3} 下的 rolling mean 曲线。BN 与 no-BN 的相对梯度变化量级接近，但 BN 在有效训练的同时保持了较低的最大 D_g 。在 2×10^{-3} 下，更关键的现象是 no-BN 的梯度方向几乎失去连续性，平均余弦仅 0.003，且模型准确率停在 10%；BN 则保持 0.154 的平均梯度余弦并正常训练到 81.36%。




图 4: 学习率 10^{-3} 下的相对梯度变化与梯度余弦相似度 rolling mean。梯度指标需要与最终准确率结合解释，避免把训练失败后的低梯度误读为稳定优化。

综合来看，梯度预测性实验并不是简单地显示 BN 在所有指标上绝对更小或更大，而是表明 BN 可以在更激进的学习率下维持有效学习，使梯度变化不至于导致训练完全崩溃。这与 loss 包络和学习率 sweep 的结论一致。

8 增强可视化实验

8.1 论文风格训练曲线

为了更直观地展示 BN 在不同学习率下的稳定性，我们将 10^{-3} 与 2×10^{-3} 两组学习率的训练/测试准确率放在同一张图中，如图 5。其中虚线表示 2×10^{-3} 。可以看到，无 BN 在该学习率下训练准确率和测试准确率均长期保持在约 10%；BN 虽然使用相同学习率，却仍能正常上升到约 80%。




图 5: 论文风格训练/测试准确率曲线。该图直接展示了 BN 对较大学习率训练的稳定作用。

8.2 三维 loss surface 可视化

除作业要求的 loss 包络外,我们还基于已训练 checkpoint 进行了二维参数切片的三维 loss surface 可视化。具体做法是取学习率 10^{-3} 下的 `best.pt`,在参数空间中采样两个 filter-normalized random directions d_1, d_2 , 计算:

$$L(w + \alpha d_1 + \beta d_2),$$

并在二维网格上绘制 loss surface。该图是高维参数空间的局部二维切片,不代表完整 loss landscape,但可以作为直观补充。




图 6: 学习率 10^{-3} 、best checkpoint 附近的二维 loss surface。左右图使用相同的采样半径与 z 轴范围,用于直观比较局部曲面形态。

从图 6 看,两种模型在最优点附近都呈现碗状结构;BN 的曲面并非在任意方向上都更平坦,但低 loss 区域更规整。这也提醒我们:单个二维切片只能作为直观展示,严谨结论仍应以跨学习率 loss 包络和准确率统计为主。

8.3 激活分布可视化

BN 的直接作用对象是中间激活分布。因此我们在学习率 10^{-3} 的 best checkpoint 上，对验证集样本进行前向传播，并采集第 1、4、8 个卷积位置附近的激活分布。对 no-BN 模型采集卷积输出；对 BN 模型采集对应 BatchNorm 层输出。图 7 展示了不同通道的 ridgeline 分布。




图 7: 不同层的激活分布 ridgeline 图。左列为标准 VGG-A，右列为 VGG-A-BN。BN 后激活在多个层上呈现更宽且更连续的通道分布形态。

表 6 给出了对应的激活统计。BN 后激活的标准差在第 1、4、8 层分别为 0.750、0.387、0.326，大于 no-BN 的 0.268、0.275、0.146。这并不矛盾，因为图中采集的是训练完成后的 BN 输出，而不是训练过程中每个 batch 的 pre-BN 到 post-BN 归一化瞬间；BN 的可学习 γ, β 会重新缩放和平移激活。更重要的是，BN 提供了受控的通道级重参数化，使网络可以在训练中学习合适尺度，而不是让每层输入分布完全由前面层的权重漂移决定。

表 6: 激活分布统计

模型	层	均值	标准差	1% 分位	99% 分位
VGG-A	1	-0.125	0.268	-0.846	0.653
VGG-A	4	-0.117	0.275	-1.273	0.227
VGG-A	8	-0.004	0.146	-0.318	0.443
VGG-A-BN	1	-0.095	0.750	-2.059	2.239
VGG-A-BN	4	-0.303	0.387	-1.440	0.627
VGG-A-BN	8	-0.015	0.326	-0.504	1.452

9 综合分析

9.1 BN 对性能的影响

在本实验中，BN 对最终性能的提升主要体现在中等和偏大学习率下。学习率 10^{-3} 时，BN 的最佳验证准确率比 no-BN 高 4.21 个百分点；学习率 2×10^{-3} 时，差距扩大到 71.36 个百分点。这说明 BN 并不是简单地在所有超参数下稳定提升，而是显著改变了模型对学习率的容忍范围。

小学习率下 BN 并不一定更优。例如 10^{-4} 和 5×10^{-5} 时，no-BN 的最佳验证准确率分别高于 BN 2.13 和 4.51 个百分点。原因可能是小学习率训练本身已经稳定，BN 带来的重参数化优势没有充分体现；同时 BN 引入的 batch 统计噪声、running statistics 误差以及额外仿射参数也可能影响最终泛化。

9.2 BN 对优化稳定性的影响

多个证据共同支持 BN 改善优化稳定性：

1. Loss 包络显著变窄。BN 的平均包络宽度仅为 0.375，无 BN 为 1.900。
2. 学习率 sweep 中，BN 在 5×10^{-4} 到 5×10^{-3} 区间均保持 75% 以上最佳验证准确率，而 no-BN 在 2×10^{-3} 和 3×10^{-3} 下失败。
3. 训练曲线显示 BN 在早期 epoch 更快达到较高验证准确率，说明它改善了优化路径，而不只是后期精调。
4. 梯度预测性实验显示，在较大学习率下 no-BN 的梯度方向连续性几乎丧失且训练失败，而 BN 仍保持有效学习。

这些结果与 Santurkar 等人在 “How Does Batch Normalization Help Optimization?” 中提出的观点一致：BN 的重要作用不是简单减少 internal covariate shift，而是通过重参数化使优化问题更加平滑，从而提高梯度下降类方法的稳定性。

9.3 局限性

本实验仍有若干局限。首先，基础训练未使用数据增强，因此最终准确率不能代表 VGG-A 在 CIFAR-10 上的最佳可达性能。其次，loss 包络方法是作业建议的简化度量，它通过不同学习

率下训练曲线的范围反映稳定性，并不是严格意义上的全局 Lipschitz 常数估计。第三，三维 loss surface 只是高维参数空间的二维随机切片，不同随机方向可能得到不同视觉形态。最后，梯度预测性指标受训练是否失败影响较大，必须结合准确率、loss 和梯度范数共同解释。

10 结论

本部分完成了 VGG-A 与 VGG-A-BatchNorm 在 CIFAR-10 上的系统对比，并从分类性能、训练曲线、loss landscape、学习率敏感性、梯度变化和激活分布等角度分析 BN 的作用。实验结论如下：

1. BN 在中等和较大学习率下显著提升 VGG-A 的训练稳定性和验证准确率。最佳结果为 82.18%，高于无 BN 模型的 79.25% 最高结果。
2. BN 显著扩大可用学习率范围。无 BN 在 2×10^{-3} 和 3×10^{-3} 下退化到 10%，而 BN 分别达到 81.36% 和 79.46%。
3. BN 缩小跨学习率 loss 包络，平均包络宽度从 1.900 降至 0.375，说明训练 loss 对学习率变化更不敏感。
4. 梯度预测性与可视化实验进一步表明，BN 改善的是训练过程中的优化动态，而不仅仅是最终分类器的表达能力。

因此，在本实验设置下，Batch Normalization 的核心价值可以概括为：通过通道级归一化和可学习重参数化，稳定深层网络的训练过程，使优化景观在实际训练路径上更加平滑，并显著提高模型对学习率选择的鲁棒性。

参考文献

- [1] Sergey Ioffe and Christian Szegedy. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. ICML, 2015.
- [2] Shibani Santurkar, Dimitris Tsipras, Andrew Ilyas, and Aleksander Madry. How Does Batch Normalization Help Optimization? NeurIPS, 2018.
- [3] Alex Krizhevsky. Learning Multiple Layers of Features from Tiny Images. Technical report, 2009.